

Intelligent Classroom HVAC Control Using Deep Reinforcement Learning: A Simulation-Based Study

Abstract. *This work presents a simulation-based study in which Deep Reinforcement Learning agents, based on the Deep Q-Network (DQN) algorithm, perform autonomous air-conditioning control in ClassroomACEnv, a Gymnasium-compatible environment parameterized after a fictitious (hypothetical) classroom. Three profiles obtained purely by reward engineering (Quadratic Plateau comfort plus an anti-short-cycling penalty) kept the room in comfort for 82.9% of the occupied time over a 3×3 grid, against 50.9% for a deadband thermostat, at an $\approx 30\%$ cost premium under a physically-coherent efficiency model. The gain is stable across seeds and generalizes without retraining (+22 to +38 pp). As the binary comfort metric saturates, we also report continuous metrics that separate the profiles. Reward modeling, more than the algorithm, proves the decisive factor.*

Resumo. *Este trabalho apresenta um estudo baseado em simulação no qual agentes de Aprendizagem por Reforço Profundo, fundamentados no Deep Q-Network (DQN), realizam o controle autônomo do ar-condicionado no ClassroomACEnv, ambiente compatível com a Gymnasium parametrizado a partir de uma sala de aula fictícia (hipotética). Três perfis obtidos apenas por engenharia de recompensa (Platô Quadrático mais penalidade anti-short-cycling) mantiveram a sala em conforto por 82,9% do tempo ocupado sobre uma matriz 3×3 , contra 50,9% de um termostato, a um prêmio de custo de $\approx 30\%$ sob eficiência fisicamente coerente. O ganho é estável entre sementes e generaliza sem re-treino (+22 a +38 pp). Como o conforto binário satura, reportamos métricas contínuas que separam os perfis. Conclui-se que a modelagem da recompensa, mais que o algoritmo, é o fator determinante.*

1. Introdução

Os sistemas de aquecimento, ventilação e ar-condicionado (*Heating, Ventilation, and Air Conditioning* – HVAC) respondem por uma parcela que frequentemente ultrapassa 40% do consumo total de energia em prédios comerciais e educacionais, de modo que a otimização do seu consumo é central para a agenda de sustentabilidade [Nascimento and Oliveira 2025]. O desafio reside na natureza complexa e dinâmica das trocas térmicas, influenciadas por variáveis estocásticas como a densidade de ocupação, a inércia térmica dos materiais e as flutuações meteorológicas externas [Pires 2013].

Tradicionalmente, o controle é feito por termostatos de regras fixas ou liga/desliga (*bang-bang*): simples, mas puramente reativos, com baixa adaptação e alternância entre subclimatização (desconforto) e acionamento abrupto. Nesse contexto, o Aprendizado por Reforço Profundo (*Deep Reinforcement Learning* – DRL) surge como alternativa: agentes aprendem políticas pela interação direta com o ambiente e, com um sinal de recompensa bem estruturado, antecipam ganhos térmicos e equilibram as demandas conflitantes de conforto e economia.

Este artigo descreve o desenvolvimento e a análise de agentes *Deep Q-Network* (DQN) para o controle de ar-condicionado em uma sala de aula simulada, conduzidos

integralmente em simulação. A transferência para o hardware é trabalho futuro. As principais contribuições são: (i) um ambiente de simulação termodinâmica compatível com a *Gymnasium*, com cargas térmicas dimensionadas para que ocupação e nível de potência sejam decisões relevantes; (ii) uma recompensa de *Platô Quadrático com gradiente* (evita o estacionamento na borda da faixa) acoplada a uma penalidade *anti-short-cycling*; (iii) três perfis (Agressivo, Equilibrado, Passivo) obtidos apenas pela variação dos pesos, traçando uma fronteira de Pareto conforto–custo; (iv) uma avaliação reprodutível sobre uma matriz 3×3 , comparando os agentes a um termostato e o controle discreto (DQN) ao contínuo (SAC), com robustez sobre sementes e generalização a salas de física distinta; e (v) mecanismos de produção (*safety shield* e trilha de auditoria) que aproximam o sistema de um cenário de implantação.

O restante do trabalho está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica; a Seção 3 discute os trabalhos relacionados; a Seção 4 detalha os materiais e métodos; a Seção 5 expõe os resultados e a discussão, incluindo a fidelidade entre simulação e realidade; e a Seção 6 conclui o trabalho.

2. Fundamentação Teórica

O Aprendizado por Reforço (*Reinforcement Learning* – RL) é um paradigma voltado a problemas de decisão sequencial, nos quais um agente aprende a selecionar ações pela interação com um ambiente, por tentativa e erro orientado por um sinal de recompensa [Li 2017]. A combinação com redes neurais profundas (DRL) ampliou sua aplicabilidade a domínios de alta dimensionalidade, de jogos e dados biológicos [Mahmud et al. 2018] a sistemas de energia [Arulkumaran et al. 2017, Xie et al. 2025].

2.1. Processo de Decisão de Markov

O problema é modelado como um Processo de Decisão de Markov (MDP), definido pela tupla (S, A, P, R, γ) — estados, ações, transição $P(s' | s, a)$, recompensa $R(s, a)$ e fator de desconto $\gamma \in [0, 1]$. A cada instante, o agente observa s_t , executa $a_t \sim \pi(a | s)$, recebe r_t e transita para s_{t+1} , maximizando o retorno acumulado esperado $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$.

2.2. Deep Q-Network (DQN)

O DQN aproxima a função de valor-ação ótima $Q^*(s, a)$ por uma rede neural $Q(s, a; \theta)$, treinada para satisfazer a equação de otimalidade de Bellman. Os parâmetros são ajustados minimizando o erro de diferença temporal:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s,a,r,s') \sim \mathcal{D}} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right], \quad (1)$$

em que $\mathcal{D}$ é o *replay buffer*, que descorrelaciona as amostras, e θ^- são os parâmetros de uma *target network* atualizada periodicamente — recursos que estabilizam o treinamento [Arulkumaran et al. 2017]. O DQN é adequado a espaços de ação discretos, como o controle do compressor em níveis fixos de potência adotado aqui.

3. Trabalhos Relacionados

No controle por aprendizado, [Platero-Horcajadas et al. 2024] integraram IoT e RL para otimizar o clima de uma estufa industrial, validando em produção e gerando economia

frente a métodos clássicos — evidência da viabilidade do RL para controle térmico em ambientes complexos. Metodologicamente, [Reiter et al. 2026] revisam a integração entre *Model Predictive Control* (MPC) e RL, destacando vantagens complementares (o MPC depende de um modelo explícito; o RL aprende da interação) que justificam métodos híbridos — pertinente a este trabalho, cuja política exibe comportamento preditivo sem modelo analítico em execução; em sistemas de energia, [Xie et al. 2025] reforçam a maturidade da técnica sob incerteza. A presente proposta diferencia-se por (i) focar o controle multinível de ar-condicionado em salas de aula, (ii) explorar a engenharia de recompensa para induzir perfis operacionais e modelar a proteção do compressor, e (iii) avaliar a política contra um *baseline* termostático em uma matriz de cenários.

4. Materiais e Métodos

A metodologia compreende a modelagem do ambiente de simulação, a formulação da recompensa e o treinamento dos agentes, em *Python* com *Gymnasium* (interface do ambiente) e *Stable-Baselines3* (DQN/SAC).

4.1. Modelagem do Ambiente e Dinâmica de Transição

O ambiente *ClassroomACEnv* foi parametrizado a partir de uma sala de aula *fictícia* (hipotética), com parâmetros físicos plausíveis e capacidade para 45 ocupantes; *não há* sala física instrumentada — todos os resultados restringem-se à simulação (cf. Seção 5.6). A transição $P(s_{t+1} \mid s_t, a_t)$ é governada por um modelo de balanço térmico agregado (*lumped*):

$$T_{t+1} = \text{clip}\left(T_t + \frac{\Delta t}{C_{\text{th}}} \cdot H_{\text{net}} + \epsilon_t, 10, 40\right), \quad H_{\text{net}} = H_{\text{ganho}} - H_{\text{resfr}}(a_t), \quad (2)$$

com $\Delta t = 0,1$ h, $\epsilon_t \sim \mathcal{N}(0, \sigma_{\text{noise}}^2)$ e $H_{\text{ganho}} = (N_{\text{ocup},t} H_p) + K_{\text{transf}}(T_{\text{ext}}(h_t) - T_t)$, em que H_p é o calor por pessoa e K_{transf} o coeficiente de troca da envoltória. A temperatura externa T_{ext} segue um modelo senoidal da hora do dia.

Um cuidado central foi *dimensionar as cargas térmicas* para que a ocupação e a escolha do nível de potência fossem decisões relevantes (Tabela 1). Com H_p ajustado, 45 ocupantes ($\approx 13,5$ u) tornam-se a carga dominante, superando o ganho externo máximo (≈ 6 u); as potências foram escalonadas de modo que LOW cubra uma sala leve, MEDIUM sustente uma sala cheia em regime e HIGH dê folga para o *pull-down* (pico $\approx 19,5$ u). Por simulação, uma sala cheia sem climatização atinge 32–36 °C, e cada nível produz um regime distinto, evitando a degeneração das ações.

Nível	OFF	LOW	MEDIUM	HIGH
Carga (fração da capacidade)	0	0,25	0,55	1,00
Potência de resfriamento (u, sim.)	0	10	22	40
Potência elétrica (kW)	0	0,64	1,35	2,93
COP (modelo físico)	—	3,45	3,59	3,00

Tabela 1. Níveis de operação, derivados do ACPhysicsModel (*split* $\approx 30\text{k BTU}$). O COP tem pico em carga parcial (MEDIUM), realista de *inverter*; a penalidade de energia é proporcional à potência elétrica, alinhando a eficiência otimizada pelo agente à da conta.

Fonte: Autores (2026).

4.2. Espaço de Ação e Observação

O espaço de ação é discreto: $A = \{\text{OFF}, \text{LOW}, \text{MEDIUM}, \text{HIGH}\} \equiv \{0, 1, 2, 3\}$. O espaço de observação é contínuo, $s_t \in \mathbb{R}^4$, com variáveis normalizadas para favorecer a convergência:

$$s_t = \left[t_{\text{norm}}, o_{\text{norm}}, \sin\left(\frac{2\pi h_t}{24}\right), \cos\left(\frac{2\pi h_t}{24}\right) \right], \quad (3)$$

em que $t_{\text{norm}} = \text{clip}((T_t - 15)/20, 0, 1)$ e $o_{\text{norm}} = N_{\text{ocup},t}/N_{\text{max}}$. A codificação cíclica da hora por seno e cosseno preserva a periodicidade do dia (sem descontinuidade 23h/0h).

4.3. Engenharia de Recompensa

A recompensa de conforto adota a topologia de *Platô Quadrático*: bônus constante na faixa $[22, 26]^\circ\text{C}$ e decaimento quadrático fora dela. Como um platô plano não incentiva *entrar* na faixa (a penalidade logo após a borda é desprezível, $k(0,1)^2 \approx 0$, levando a estacionar pouco acima de 26°C), introduzimos um *gradiente* interno (B_c , máximo no centro), tornando 24°C estritamente preferível à borda:

$$R_{\text{conforto}} = \begin{cases} B + B_c \left(1 - \frac{|T_{t+1} - 24|}{2}\right) & T_{\min} \leq T_{t+1} \leq T_{\max}, \\ B - k (T_{t+1} - T_{\max})^2 & T_{t+1} > T_{\max}, \\ B - k (T_{\min} - T_{t+1})^2 & T_{t+1} < T_{\min}. \end{cases} \quad (4)$$

A Figura 1 compara as três formulações: quadrática pura, platô plano e o platô com gradiente adotado.




Figura 1. Funções de recompensa de conforto. O platô plano (azul) não recompensa entrar na faixa; o platô com gradiente (laranja) torna o centro estritamente melhor.

Fonte: Autores (2026).

A recompensa total agrega ainda: R_{energia} , proporcional ao consumo e escalonada em horário de pico (18h–21h); $R_{\text{mudança}}$, custo por troca de estado ($a_t \neq a_{t-1}$); e R_{frio} , que penaliza resfriar abaixo do limite inferior. Para modelar a *proteção física do compressor contra ciclagem rápida (short-cycling)*, adicionou-se uma penalidade extra escalonada quando o agente troca de estado antes de cumprir um tempo mínimo de permanência $d_{\min}$ (36 min):

$$R_{\text{ciclo}} = \begin{cases} \rho \cdot \frac{d_{\min} - \tau}{d_{\min}} & \text{se trocou e } \tau < d_{\min}, \\ 0 & \text{caso contrário,} \end{cases} \quad (5)$$

em que τ é o número de passos desde a última troca e $\rho < 0$. A recompensa consolidada é $R_t = R_{\text{conforto}} + R_{\text{energia}} + R_{\text{mudança}} + R_{\text{frio}} + R_{\text{ciclo}}$.

4.4. Perfis Operacionais e Protocolo Experimental

Mantendo a arquitetura (*MlpPolicy*) e os hiperparâmetros do DQN (taxa = 5×10^{-5} , *batch* 64, *action repeat* 2), três perfis foram obtidos *apenas* variando os pesos da recompensa (Tabela 2): o **Agressivo** prioriza o conforto, o **Passivo** a economia e o **Equilibrado** fica entre eles. Cada agente foi treinado por 550k *timesteps* com semente fixa. Os pesos foram definidos empiricamente.

Perfil	Gradiente B_c	Penal. Energia	Penal. Troca
Agressivo	7,0	0,03	−0,5
Equilibrado	4,0	0,10	−1,5
Passivo	3,0	0,12	−1,5

Tabela 2. Pesos de recompensa que definem os três perfis operacionais.

Fonte: Autores (2026).

A avaliação emprega uma matriz 3×3 (Tabela 3) que cruza três faixas de temperatura inicial com três níveis de ocupação, totalizando nove cenários simulados por 24 h.

O conforto é medido na *janela ocupada* (7h–22h). Como o equipamento apenas resfria, um cenário só é incluído na média de conforto se um contrafactual (AC sempre desligado) ultrapassaria 26 °C — isto é, se resfriar era de fato necessário; nos demais, o desconforto possível (“frio demais”) é incontrolável por um AC. O *baseline* é um termostato com zona morta (*deadband*).

Condição inicial	Poucas (5)	Médias (22)	Muitas (45)
Frio (17 °C, início 7h)	C1	C2	C3
Normal (24 °C, início 10h)	C4	C5	C6
Quente (30 °C, início 14h)	C7	C8	C9

Tabela 3. Matriz 3×3 de cenários de avaliação (temperatura inicial $\times$ ocupação). Cada célula (C1–C9) corresponde a um episódio de 24 h; o conforto é medido na janela ocupada (7h–22h).

Fonte: Autores (2026).

4.5. Controlador de ação contínua (SAC)

Além dos perfis discretos (DQN), treinamos um controlador de *ação contínua* para avaliar o efeito da granularidade da atuação: a ação passa a ser uma *fração de potência* $a \in [0, 1]$, otimizada pelo *Soft Actor-Critic* (SAC) sob o *mesmo orçamento* (550k timesteps) e avaliada nos mesmos cenários. A hipótese é que a modulação contínua produza um controle mais suave, reduzindo a comutação do compressor.

5. Resultados e Discussão

A Tabela 4 consolida o desempenho médio sobre a matriz 3×3 dos três perfis *discretos* (DQN) frente ao termostato (o SAC é analisado na Seção 5.3). Os perfis mantiveram a sala em conforto por 82,9% do tempo ocupado, contra 50,9% do termostato (+32 pp), com comutação (2,5–2,9/h) próxima à do termostato (2,5) — a penalidade *anti-short-cycling* conteve a oscilação apesar do controle mais fino. O custo usa tarifa real (R\$ 0,80/kWh, $\times 1,6$ no pico 18h–21h) sobre a potência elétrica de cada nível.

Agente	Conf. [22,26] (%)	Conf. [23,25] (%)	$ T-24 $ (°C)	Sobreaq. (%)	Energia (kWh/dia)	Custo (R\$/dia)	Trocas /h
Agressivo	82,9	83,9	0,86	5,4	15,59	13,64	2,91
Equilibrado	82,9	78,1	0,99	5,4	14,65	12,73	2,45
Passivo	82,9	79,6	0,97	5,4	15,28	13,31	2,57
Termostato (<i>baseline</i>)	50,9	6,4	2,21	41,4	10,91	9,81	2,50

Tabela 4. Desempenho dos três perfis DQN vs. termostato na matriz 3×3 (semente principal; janela ocupada 7h–22h; energia e custo em base diária). Além do conforto binário na faixa larga [22, 26] (que *satura*: os três perfis empatam), reporta-se a faixa estreita [23, 25], o desvio médio do ideal $|T - 24|$ (qualidade de controle) e o sobreaquecimento (% acima de 26 °C, a falha que o AC *pode* evitar). Métricas refinadas calculadas sobre os 8/9 cenários controláveis.

Fonte: Autores (2026).

Os três perfis empatam em 82,9% de conforto binário porque essa métrica *satura*: ela apenas verifica se $22 \leq T \leq 26$, sem distinguir uma sala a 24 °C de outra a 25,9 °C. Com a faixa larga de 4 °C, qualquer política competente fica dentro quase sempre, e os 17,1% restantes são *estruturais* — *pulldown* nos cenários quentes e reaquecimento nos frios —, idênticos entre perfis pois nenhum agente os encurta. As três métricas contínuas, porém, separam os perfis: o **Agressivo** assenta a sala mais perto de 24 °C ($|T - 24| = 0,86$ °C; 83,9% em [23, 25]), enquanto Equilibrado e Passivo tangenciam o teto ($\approx 0,98$ °C; 78–80%), gastando menos energia; o termostato, estacionado em ≈ 26 °C, fica a 2,21 °C do ideal com 41,4% de sobreaquecimento (contra 5,4% dos agentes, o piso físico do *pulldown*). A Figura 2 torna a diferença visível: as distribuições dos perfis de RL concentram-se em torno do ideal, ao passo que a do termostato está deslocada para o teto.




Figura 2. Distribuição da temperatura na janela ocupada por controlador (violino + *boxplot*, cenários controláveis agrupados). O conforto binário [22, 26] empata os três perfis em 82,9%, mas as distribuições diferem: o Agressivo (azul) concentra-se no ideal ($|T - 24| = 0,86$), Equilibrado/Passivo assentam acima, e o termostato (vermelho) estaciona no teto ($|T - 24| = 2,21$).

Fonte: Autores (2026).

Robustez sobre múltiplas sementes. Retreinando cada perfil com três sementes, o conforto mostrou-se estável — $82,6 \pm 0,4$ (Agressivo), $82,9 \pm 0,0$ (Equilibrado) e $82,4 \pm 0,7$ (Passivo) pp —, assim como a métrica contínua $|T - 24|$ ($0,97 \pm 0,20$; $0,96 \pm 0,03$; $1,03 \pm 0,08$ °C), confirmando que a vantagem de ≈ 32 pp e o ordenamento entre perfis não são fruto do acaso. O custo também foi estável ($\approx$ R\$ 12,7–13,1/dia, desvio $\approx$ R\$ 0,5), porém *superior* ao do termostato (R\$ 9,81): sob a eficiência coerente, este é barato por subclimatizar e operar no MEDIUM (maior COP). Em síntese, o ganho do RL é o *conforto*, a um prêmio de $\approx 30\%$ — um *trade-off* honesto.

5.1. Conforto e comportamento por cenário

A vantagem do RL é maior justamente nos cenários exigentes, e cresce com a ocupação: por cenário (perfil Equilibrado), em “Normal” o conforto do termostato cai de 85% para 43% de 5 a 45 pessoas, enquanto o DQN mantém 100%; nos quentes de ocupação máxima, o DQN sustenta 82% contra 26% do termostato. A única exceção é “Frio + Poucas” (50% para ambos): com a sala a 17 °C e um equipamento que apenas resfria, a

única ação correta é aguardar o aquecimento natural. Restringindo-se aos cenários em que resfriar era de fato necessário (excluindo os de partida fria), o conforto médio dos agentes sobe para $\approx 98\%$. Temporalmente, nos cenários quentes os agentes realizam o *pull-down* e sustentam a faixa enquanto o termostato permanece acima de 26°C oscilando *bang-bang*; no normal, seguram a temperatura na faixa enquanto o termostato a deixa derivar.

5.2. Perfis e a fronteira de Pareto

A Figura 3 dispõe os três perfis DQN e o termostato no plano conforto–custo. Entre os perfis de RL, o Equilibrado é o de menor custo (R\$ 12,73) e Agressivo/Passivo pagam um pequeno prêmio; todos atingem o mesmo conforto *binário* (82,9%), ajustável apenas pelos pesos da recompensa. O termostato ocupa um canto distinto (baixo conforto, 50,9%, a baixo custo, R\$ 9,81): sob a eficiência coerente, os perfis de RL *não dominam* o termostato em custo — compram +32 pp de conforto a um prêmio de $\approx 30\%$. Embora a faixa larga [22, 26] faça os três convergirem no binário, a Tabela 4 e a Figura 2 mostram que eles *de fato* diferem em onde assentam a sala ($|T - 24|$ de 0,86 a 0,99 $^\circ\text{C}$) — é a métrica, não a política, que achata a distinção; separá-los no próprio conforto exigiria estreitar a faixa ou *setpoints* distintos por perfil.




Figura 3. Trade-off conforto $\times$ custo (média da matriz 3×3). Os perfis DQN convergem em conforto (82,9%) e se separam no custo (Equilibrado o mais barato); o termostato ocupa um canto de baixo conforto e baixo custo — o RL troca custo por conforto.

Fonte: Autores (2026).

5.3. Controle discreto (DQN) vs. contínuo (SAC)

A Tabela 5 confronta os três controladores. Como o SAC é um *único* agente (não há perfis no caso contínuo), adota-se o perfil **Equilibrado** como DQN representativo — o de menor custo entre os três perfis (Tabela 4) — em toda esta comparação. O DQN (Equilibrado) supera amplamente o termostato em conforto (82,9% contra 50,9%), a um gasto maior — o termostato, subclimatizando no nível MEDIUM (maior COP), consome menos. O SAC troca conforto por suavidade: atinge 74,5% (abaixo do DQN), com controle *mais suave* — 27 ajustes de potência por dia contra 59 do DQN ($\approx 54\%$ menos), reduzindo a

fadiga de liga/desliga do compressor. A escolha discreto $\times$ contínuo passa, portanto, por priorizar o conforto (DQN) ou a integridade do *hardware* (SAC).

Controlador	Conf. [22,26] (%)	Conf. [23,25] (%)	$ T-24 $ (°C)	Energia (kWh/dia)	Gasto (R\$/dia)	Mud. estado /dia
DQN — Equilibrado (4 níveis)	82,9	78,1	0,99	14,65	12,73	59
SAC (contínuo)	74,5	62,8	1,32	16,47	15,25	27
Termostato (<i>baseline</i>)	50,9	6,4	2,21	10,91	9,81	60

Tabela 5. DQN (perfil Equilibrado) vs. SAC vs. termostato (RL com mesmo orçamento de 550k passos; médias da matriz 3×3). “Mud. estado” = comutações de nível (DQN/termostato) ou ajustes significativos de potência (SAC). O DQN domina o SAC tanto no conforto binário quanto nas métricas contínuas ($|T - 24|$ menor, mais tempo em [23, 25]).

Fonte: Autores (2026).

A Figura 4 torna visível essa diferença: enquanto o DQN alterna abruptamente entre os quatro níveis discretos (0/33/67/100% de potência), o SAC modula a potência de forma contínua e suave, mantendo a temperatura na mesma faixa com transições menos bruscas — o que reduz o estresse mecânico sobre o compressor.




Figura 4. Controle discreto (DQN, perfil Equilibrado) vs. contínuo (SAC) no mesmo cenário. O painel inferior mostra a potência do AC: o DQN opera em degraus (0/33/67/100%); o SAC modula continuamente.

Fonte: Autores (2026).

5.4. Aspectos de produção: segurança e observabilidade

Com vistas à transição para um sistema real, dois *wrappers* foram incorporados. O *escudo de segurança* sobrescreve a ação nos limites de temperatura (resfria acima de 28 °C, desliga abaixo de 20 °C), garantindo segurança térmica *independentemente* da política e mitigando o *reward hacking*. O *registrador de decisões* produz uma trilha de auditoria

estruturada (estado, ação, recompensa e motivo legível por passo), endereçando observabilidade e auditabilidade.

5.5. Generalização a outras salas

O agente Equilibrado — treinado em uma única sala ($C_{th} = 15$, $K_{transf} = 0,5$) — foi avaliado, *sem retreino*, em salas de inércia térmica (leve a pesada) e isolamento (bom a ruim) distintos. A Tabela 6 mostra que a política transfere bem: mantém vantagem de +21,7 a +38,5 pp sobre o termostato em *todas* as variações, com degradação suave apenas em salas muito pesadas ($C_{th} = 30$), naturalmente mais lentas. Isso indica uma estratégia de controle robusta, e não um ajuste fino à física da sala de treino.

Sala (variação física)	Conf. DQN (%)	Conf. Term. (%)	Δ (pp)
<i>Inércia térmica</i> ($K_{transf} = 0,5$)			
$C_{th} = 10$ (leve)	88,6	51,3	+37,3
$C_{th} = 15$ (treino)	83,2	51,0	+32,2
$C_{th} = 20$	77,6	49,4	+28,2
$C_{th} = 30$ (pesada)	67,5	45,8	+21,7
<i>Envoltória</i> ($C_{th} = 15$)			
$K_{transf} = 0,3$ (bem isolada)	80,3	51,9	+28,4
$K_{transf} = 0,5$ (treino)	83,2	51,0	+32,2
$K_{transf} = 0,8$ (mal isolada)	85,3	46,7	+38,5

Tabela 6. Generalização: o agente Equilibrado (treinado em $C_{th} = 15$, $K_{transf} = 0,5$) avaliado sem retreino em salas com física distinta. Conforto médio na matriz 3×3 ; Δ = vantagem sobre o termostato.

Fonte: Autores (2026).

5.6. Fidelidade entre simulação e ambiente real

Os resultados restringem-se à simulação. O balanço térmico é agregado (sala como nó único, ignorando gradientes espaciais, umidade e CO_2), a temperatura externa segue uma senoide idealizada e o atuador é instantâneo, ao passo que compressores reais têm latência e ciclos de partida (a penalidade *anti-short-cycling* endereça isso apenas em parte). A transferência segura exigiria calibrar o simulador com telemetria real e aplicar *domain randomization* para reduzir a lacuna *sim-to-real*.

6. Conclusão

Este trabalho avaliou, em simulação, o Aprendizado por Reforço Profundo (*Deep Q-Network*) no controle de climatização em salas de aula. As políticas mantiveram o conforto em 82,9% do tempo ocupado, contra 50,9% de um termostato com zona morta, a um *prêmio* de custo de $\approx 30\%$ sob eficiência coerente (o termostato é barato por subclimatizar). Mostramos ainda que o conforto binário *satura*: os três perfis empatam, mas se separam sob métricas contínuas ($|T - 24|$ de 0,86 a 0,99 °C) — a distinção é achatada pela métrica, não ausente nas políticas.

O principal achado é que o sucesso do controle por RL depende, sobretudo, da formulação da recompensa. O Platô Quadrático com gradiente, aliado às penalidades de troca e de *short-cycling*, produziu controle suave e preditivo, e a simples variação dos pesos derivou três perfis que traçam uma fronteira de Pareto conforto–custo — embora uma calibração mal feita (penalidade severa no frio) tenha chegado a induzir “medo de resfriar”, degradando a política. A comparação discreto $\times$ contínuo mostrou que o SAC troca ≈ 8 pp de conforto por 54% menos ajustes de potência, favorável à longevidade do compressor. O conforto manteve-se estável sobre três sementes (± 1 pp) e generalizou, sem retreino, a salas de inércia e isolamento distintos (+22 a +38 pp sobre o termostato).

Como limitações, permanecem a ausência de validação em *hardware* e a definição empírica dos pesos. Como trabalhos futuros: (i) busca sistemática (*e.g.*, Optuna) que posicione cada perfil em um ponto validado da fronteira; (ii) dados meteorológicos reais e calibração do modelo térmico com telemetria; (iii) *domain randomization*; e (iv) a transferência para o hardware de IoT, fechando o ciclo *sim-to-real*.

Referências

- Arulkumaran, K., Deisenroth, M. P., Brundage, M., and Bharath, A. A. (2017). Deep reinforcement learning: A brief survey. *IEEE signal processing magazine*, 34(6):26–38.
- Li, Y. (2017). Deep reinforcement learning: An overview. *arXiv preprint arXiv:1701.07274*.
- Mahmud, M., Kaiser, M. S., Hussain, A., and Vassanelli, S. (2018). Applications of deep learning and reinforcement learning to biological data. *IEEE Transactions on Neural Networks and Learning Systems*, 29(6):2063–2079.
- Nascimento, E. F. and Oliveira, P. P. (2025). Eficiência energética em edificações: estratégias e tecnologias para redução do consumo energético e sustentabilidade. *Revista Multidisciplinar do Nordeste Mineiro*, 7(1):1–17.
- Pires, J. R. (2013). Investigação da viabilidade da redução do consumo de energia elétrica em edificações residenciais através da aplicação de soluções de conforto ambiental passivo. Master’s thesis, Nome da Instituição, Cidade.
- Platero-Horcajadas, M., Pardo-Pina, S., Cámara-Zapata, J.-M., Brenes-Carranza, J.-A., and Ferrández-Pastor, F.-J. (2024). Enhancing greenhouse efficiency: Integrating iot and reinforcement learning for optimized climate control. *Sensors*, 24(24).
- Reiter, R., Hoffmann, J., Reinhardt, D., Messerer, F., Baumgärtner, K., Sawant, S., Bödecker, J., Diehl, M., and Gros, S. (2026). Synthesis of model predictive control and reinforcement learning: Survey and classification. *Annual Reviews in Control*, 61:101045.
- Xie, H., Song, G., Shi, Z., Zhang, J., Lin, Z., Yu, Q., Fu, H., Song, X., and Zhang, H. (2025). Reinforcement learning for vehicle-to-grid: A review. *Advances in Applied Energy*, 17:100214.